

MATRIZ DE CONSISTENCIA Y PLAN DE GENERALIZACIÓN FUERA DE MUESTRA

Análisis de Sentimiento en Noticias Macroeconómicas mediante Inteligencia Artificial para la Generación de Señales de Apoyo a la Toma de Decisiones en Tesorería Bancaria

Curso: Proyecto de Investigación II

Alumno: Thomy Jefferson Villanueva Quinteros

1. Alineamiento general

Elemento	Formulación preliminar
Problema / pregunta general	¿En qué medida el sentimiento agregado de noticias macroeconómicas y financieras puede transformarse en señales útiles para apoyar el análisis de los movimientos diarios del tipo de cambio USD/PEN mediante técnicas de Inteligencia Artificial?
Objetivo general	Desarrollar y evaluar un sistema basado en Inteligencia Artificial que transforme noticias macroeconómicas y financieras en indicadores cuantitativos de sentimiento para generar señales experimentales de apoyo al análisis del comportamiento del tipo de cambio USD/PEN.
Hipótesis general	El sentimiento agregado de noticias macroeconómicas y financieras contiene información relevante que puede transformarse en indicadores cuantitativos útiles para apoyar el análisis de los movimientos diarios del tipo de cambio USD/PEN.
Unidad de análisis	Día de negociación del mercado cambiario USD/PEN. Cada observación corresponde al resumen diario del sentimiento agregado de noticias macroeconómicas y financieras y su comparación con el movimiento observado del tipo de cambio. Dataset preliminar: 2,906 noticias limpias, 2,849 noticias clasificadas, 122 días con sentimiento agregado y 88 registros finales modelables.
Alcance actual del modelo	La versión experimental actual formula el problema como clasificación binaria: UP frente a NO_UP. Es decir, el modelo identifica si el USD/PEN sube o no sube.

Matriz de consistencia preliminar

Obj.	Objetivo específico	Hipótesis específica	VI / condición de estudio	VD / resultado medido	Variables de control	Operacionalización e indicadores	Escala	Generalización fuera de muestra
OE1	Construir indicadores diarios de sentimiento a partir de noticias macroeconómicas y financieras mediante técnicas de Procesamiento de Lenguaje Natural.	H1: Los indicadores derivados del análisis de sentimiento permiten representar cuantitativamente el comportamiento agregado de las noticias macroeconómicas y constituyen variables observables para el modelado del USD/PEN.	Indicadores diarios de sentimiento construidos a partir de noticias clasificadas como positivas, neutrales o negativas.	Calidad y disponibilidad del indicador diario de sentimiento. Se mide mediante cobertura diaria, consistencia de valores y capacidad de agregación temporal.	Mismas fuentes de noticias, mismo proceso de limpieza, mismo modelo de sentimiento por idioma, misma lógica de agregación diaria y misma ventana temporal.	Indicadores: <code>sent_index_mean</code> , <code>sent_index_strength</code> , <code>share_pos</code> , <code>share_neg</code> , <code>share_neu</code> , <code>n_news_total</code> . Dataset: 2,906 noticias limpias, 2,849 noticias clasificadas y 122 días con sentimiento agregado.	Razón continua para indicadores; conteo para volumen de noticias; proporciones entre 0 y 1.	Aplicar el mismo pipeline congelado sobre noticias posteriores, sin modificar reglas de limpieza ni modelos de sentimiento. Comparar cobertura, polaridades y estabilidad del índice.
OE2	Diseñar y comparar estrategias de ingeniería de atributos temporales para determinar qué variables de sentimiento aportan mayor capacidad predictiva.	H2: La incorporación de rezagos temporales del sentimiento, especialmente <code>lag_sent_1</code> y <code>lag_sent_2</code> , mejora el desempeño respecto a utilizar únicamente el sentimiento del día anterior.	Tipo de conjunto de atributos: <code>Baseline_lag1</code> , <code>Var1_lag1_lag2</code> , <code>Var2_lags_volume_share</code> , <code>Var3_full_temporal</code> .	Desempeño predictivo de cada variante medido con PR-AUC, F1, Accuracy, Precision y Recall.	Mismo dataset modelable, misma variable objetivo, misma semilla, misma partición temporal, mismo protocolo de validación, mismas métricas y mismo preprocesamiento.	Resultados preliminares: Baseline PR-AUC = 0.646; Var1 PR-AUC = 0.679; Var2 PR-AUC = 0.651; Var3 PR-AUC = 0.660.	Razón continua entre 0 y 1 para métricas; nominal para tipo de variante.	Evaluar las mismas variantes en nuevas ventanas temporales. Si Var1 mantiene mejor desempeño, se refuerza la hipótesis de que la memoria temporal corta aporta señal.
OE3	Optimizar y seleccionar el modelo de Machine Learning con mejor capacidad de discriminación para generar señales experimentales sobre el USD/PEN.	H3: Un Random Forest optimizado mediante Random Search presenta mayor PR-AUC que Logistic Regression para discriminar días UP y NO_UP.	Familia de modelo y configuración de hiperparámetros: Logistic Regression frente a Random Forest.	Capacidad de discriminación del modelo medida mediante PR-AUC, completada con Precision, Recall, F1, Accuracy y matriz de confusión.	Mismos atributos ganadores, mismo dataset, mismos folds, misma semilla, mismo criterio de selección, misma métrica central PR-AUC y mismo pipeline.	Random Search con aprox. 30 configuraciones de Logistic Regression y 30 de Random Forest. Mejor resultado: Random Forest, PR-AUC CV = 0.692 y PR-AUC holdout = 0.779.	Razón continua entre 0 y 1 para métricas; nominal para familia de modelo; discreta para hiperparámetros.	Congelar el modelo ganador y evaluarlo sobre periodos posteriores no usados en entrenamiento. Reportar degradación de PR-AUC, matriz de confusión y estabilidad.
OE4	Implementar una visualización interactiva que permita explorar resultados, comparar modelos y comunicar señales de manera reproducible.	H4: Un dashboard interactivo facilita la interpretación de resultados y mejora la trazabilidad del experimento frente a una revisión basada solo en tablas estáticas.	Disponibilidad de dashboard web con filtros, selector de modelo y visualización de resultados.	Capacidad de exploración y comunicación: filtros, semáforo de predicciones, matriz de confusión, probabilidad de subida, descarga de CSV y métricas.	Mismos archivos exportados, misma versión del branch, mismos logs, mismo dataset de dashboard, mismos artefactos y mismo modelo ganador.	Indicadores: URL pública en GitHub Pages, existencia de <code>docs/index.html</code> , <code>docs/script.js</code> , <code>week8_dashboard_data.csv</code> , matriz de confusión y Top-K. Dashboard: https://thomyvq.github.io/news-sentiment-pipeline-usdpn/ .	Nominal dicotómica para disponibilidad; razón para métricas; nominal para selección de modelo.	Publicar el dashboard sobre branch versionado y actualizarlo con nuevos datos. Validar que la web funcione con datos futuros sin modificar la lógica principal.

3. Operacionalización básica de variables

Variable	Definición conceptual	Indicadores / medición operacional	Escala
Sentimiento agregado de noticias	Nivel agregado de polaridad informativa presente en noticias macroeconómicas y financieras.	sent_index_mean, sent_index_strength, share_pos, share_neg, share_neu.	Razón continua.
Memoria temporal del sentimiento	Persistencia del sentimiento en días anteriores que podría influir en el comportamiento posterior del tipo de cambio.	lag_sent_1, lag_sent_2, lag_sent_3, rolling_sent_3, rolling_sent_5.	Razón continua.
Volumen informativo	Cantidad de noticias disponibles en un día determinado.	n_news_total, lag_news_1.	Conteo / razón.
Movimiento del USD/PEN	Dirección observada del tipo de cambio diario.	target_up: 1 = UP; 0 = NO_UP.	Nominal dicotómica.
Desempeño predictivo	Capacidad del modelo para discriminar días de subida frente a no subida.	PR-AUC, F1, Accuracy, Precision, Recall, matriz de confusión, hit rate.	Razón entre 0 y 1.
Tipo de modelo	Familia de algoritmo utilizada para generar la señal.	Logistic Regression, Random Forest.	Nominal.

4. Plan operativo de generalización fuera de la muestra

Escenario	Procedimiento	Entregable mínimo
Opción principal: holdout temporal futuro	Entrenar con la ventana histórica inicial y evaluar sobre una ventana posterior nunca utilizada en entrenamiento. Mantener congelados el pipeline, las features y los hiperparámetros del modelo ganador.	Tabla CV vs holdout futuro; PR-AUC, F1, Accuracy, Precision, Recall, matriz de confusión y breve análisis de degradación.
Backtesting temporal	Simular operación real mediante ventanas temporales: entrenar hasta t_{k-1} y evaluar en t_k . Repetir el proceso en varias ventanas cronológicas.	Tabla por ventana temporal y gráfico de evolución de PR-AUC / F1. Identificación de periodos donde el modelo se degrada.
Generalización por fuente	Evaluar si el modelo mantiene desempeño cuando se incorporan nuevas fuentes de noticias o cuando se deja fuera una fuente específica para probar robustez.	Tabla por fuente o grupo de fuentes; comparación de distribución de sentimiento y cambio en métricas.
Robustez ante shift de datos	Medir cambios de distribución entre entrenamiento y evaluación: proporción de clases, distribución del sentimiento, volumen de noticias y variación del USD/PEN.	Reporte de shift: cambio en target rate, cambio en sent_index_mean, cambio en share_neu y Top variables con mayor variación.
Plan B si no hay datos externos suficientes	Aplicar particiones robustas con Stratified K-Fold, TimeSeriesSplit, validación por ventanas y perturbaciones sintéticas moderadas sobre variables de sentimiento.	Tabla comparativa de validaciones internas y análisis de sensibilidad. Reportar media, desviación estándar e intervalos de confianza si es posible.

5. Nota metodológica

La versión actual del proyecto ya incorpora mecanismos iniciales de generalización y reproducibilidad: holdout temporal, Stratified K-Fold complementario, Random Search, logs en CSV, configuración ganadora en JSON, modelo exportado en formato `joblib` y dashboard interactivo desplegado en GitHub Pages. No obstante, se reconoce que el tamaño actual del dataset modelable todavía es limitado. Por ello, la generalización fuera de muestra deberá reforzarse incorporando nuevas ventanas temporales, mayor cobertura histórica y variables macroeconómicas adicionales como DXY, tasas FED, inflación, commodities y riesgo país.